

新疆大学本科毕业论文（设计）



新疆大学
Xinjiang University

论文题目：棉花病虫害识别系统的

设计与实现

学生姓名：冶文

学 号：20201405005

所属院系：计算机科学与技术学院

专 业：网络空间安全

班 级：网安 20-3

指导老师：程述立

日 期：2024 年 4 月 18 日

声 明

本人郑重声明，本论文是在导师的指导下独立完成，除加注和致谢外，文中不包含他人所发表或撰写的成果。本人拥有自主知识产权，没有抄袭、剽窃他人成果，对于参考的文献已经加注并表示感谢。若有不实之处，本人愿意承担相关法律责任。

作者签名：

签字日期： 年 月 日

本科学位论文（设计）版权使用授权书

本人完全了解学校有关保留、使用本科学位论文（设计）的规定，同意学校保留并向国家有关部门或机构送交论文（设计）的复印件和电子版，允许论文（设计）被查阅和借阅。本人授权新疆大学将本学位论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文（设计）。

本学位论文（设计）属于：

保 密 ☐，在__年解密后适用本授权书。

不保密 ☒。

作者签名：

日 期： 年 月 日

指导教师签名：

日 期： 年 月 日

摘 要

随着深度学习技术在计算机视觉领域的快速发展，其在图像识别任务中的应用变得日益广泛。棉花作为全球经济作物的重要组成部分，其健康生长对农业生产至关重要。然而，棉花在生长过程中易受到多种病虫害的威胁，这不仅影响棉花的产量和品质，还可能造成巨大的经济损失。因此，开发一种能够准确识别棉花病虫害的系统，对于及时防治病虫害、保障棉花生产具有重要的现实意义。

本文针对棉花病虫害识别问题，提出了一种基于深度学习的识别方法。首先，对现有的卷积神经网络（Convolutional Neural Networks，简称 CNN）模型进行了深入分析，选择了 MobileNetV2 作为基础模型。MobileNetV2 以其高效的计算能力和较低的资源消耗，在多个图像识别任务中展现了出色的性能。为了进一步提升模型对图像关键区域的识别能力，本文引入了 EMA (Efficient Multi-scale Attention, EMA) 高效的多尺度注意力机制。通过在 MobileNetV2 中嵌入注意力模块 EMA，模型能够更加集中地识别图像中与病虫害相关的特征，从而提高了识别的准确性。

为了验证所提出方法的有效性，本文在棉花病虫害数据集上进行了广泛的实验，并与其他五种主流图像识别算法进行了比较。实验结果表明，引入注意力机制的 MobileNetV2 在准确率（ACC）、损失函数（LOSS）和参数量等关键评价指标上均优于对比算法，充分证明了注意力机制在提升棉花病虫害图像识别性能方面的有效性。

基于实验结果的积极反馈，本文进一步设计并实现了一套用户友好的棉花病虫害识别系统。该系统基于改进的 MobileNetV2 模型，提供了简洁的操作流程和直观的用户界面，使得非专业用户也能轻松地进行棉花病虫害的识别和分类。

总结而言，本文不仅提出了一种结合注意力机制的棉花病虫害图像识别算法，并在实验中取得了优异的性能，还开发了相应的识别系统，为农业生产提供了实用的技术支持。

关 键 词：深度学习；图像识别；棉花病虫害；MobileNetV2；注意力机制

ABSTRACT

With the rapid development of deep learning technology in the field of computer vision, its application in image recognition tasks has become increasingly widespread. Cotton, as an important component of global cash crops, its healthy growth is crucial to agricultural production. However, cotton is susceptible to various diseases and pests during its growth, which not only affects the yield and quality of cotton but may also cause significant economic losses. Therefore, developing a system capable of accurately identifying cotton diseases and pests is of great practical significance for timely prevention and control of diseases and pests, and ensuring cotton production.

In this paper, aiming at the problem of cotton disease and pest identification, a deep learning-based recognition method is proposed. Firstly, an in-depth analysis of the existing Convolutional Neural Network (CNN) models was conducted, and MobileNetV2 was selected as the base model. MobileNetV2 has demonstrated excellent performance in multiple image recognition tasks due to its efficient computational capabilities and low resource consumption. To further enhance the model's ability to recognize key areas of the image, this paper introduces the EMA (Efficient Multi-Scale Attention, EMA) attention mechanism. By embedding the EMA attention module into MobileNetV2, the model can more focusedly identify features related to diseases and pests in the image, thereby improving the accuracy of recognition.

To verify the effectiveness of the proposed method, extensive experiments were conducted on a cotton disease and pest dataset in this paper, and comparisons were made with five other mainstream image recognition algorithms. The experimental results show that MobileNetV2 with the attention mechanism outperforms the comparative algorithms in key evaluation metrics such as accuracy (ACC), loss function (LOSS), and the amount of parameters, fully demonstrating the effectiveness of the attention mechanism in enhancing the performance of cotton disease and pest image recognition.

Based on the positive feedback from the experimental results, this paper further designed and implemented a user-friendly cotton disease and pest identification system. The system, based on the improved MobileNetV2 model, provides a concise

operation process and an intuitive user interface, enabling non-professional users to easily perform the identification and classification of cotton diseases and pests.

In summary, this paper not only proposes an image recognition algorithm for cotton diseases and pests combined with the attention mechanism and has achieved excellent performance in experiments, but also develops the corresponding recognition system, providing practical technical support for agricultural production.

KEY WORDS:Deep learning;Image recognition;Cotton diseases and pests; MobileNetV2; Attention mechanism

目 录

1 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.3 主要研究内容	3
1.4 论文结构安排	4
2 相关理论与技术	5
2.1 卷积神经网络	5
2.2 经典卷积神经网络模型研究	6
2.2.1 DenseNet121	6
2.2.2 ResNet18	7
2.2.3 ResNet50	7
2.2.4 VGG16	8
2.3 系统开发相关技术	9
2.3.1 PyTorch 深度学习框架	9
2.3.2 Vue 框架	9
2.4 数据集和评价指标	10
2.4.1 数据集	10
2.4.2 评价指标	10
2.5 本章小结	10
3 棉花病虫害识别算法	12
3.1 引言	12
3.2 MobileNetV2 模型整体框架	12
3.3 基于 MobileNetV2 的改进型棉花病虫害识别算法	14
3.3.1 改进的 MobileNetV2 模型整体框架	14
3.3.2 注意力模块	14
3.3.3 损失函数	16
3.4 实验结果及分析	17
3.4.1 实验参数设置	17
3.4.2 对比算法分析	17
3.4.3 可视化结果展示	23
3.5 本章小结	24
4 棉花病虫害识别系统的设计与实现	26
4.1 系统需求分析	26
4.2 系统的设计与功能	26
4.2.1 系统架构设计	26

4.2.2 系统功能模块设计	27
4.3 系统实现	28
4.4 系统测试	31
4.4.1 软硬件环境	31
4.4.2 测试内容	32
4.5 本章小结	32
5 总结与展望	34
5.1 总结	34
5.2 展望	35
参考文献	36
致 谢	38

1 绪论

1.1 研究背景与意义

棉花作为全球重要的经济作物之一，其产量和质量对农业经济和国际贸易具有重大影响。根据联合国粮农组织（FAO）的报告，棉花产业为全球提供了大量的就业机会，并为许多国家的经济发展做出了重要贡献。然而，棉花生长过程中易受到多种病虫害的侵害，如棉花黄萎病、棉铃虫和红蜘蛛等，这些病虫害不仅影响棉花的生长发育，还可能导致产量大幅下降，严重时甚至会造成绝收。根据《农业和应用经济学杂志》上的研究，病虫害导致的产量损失可高达 40%。因此，及时准确地识别和防治棉花病虫害对于保障棉花产业的可持续发展具有重要意义。

为了应对这一挑战，棉花病虫害识别系统的设计与实现对于农业领域具有重要的意义。传统的病虫害识别方法依赖于农业专家的人工观察和经验判断，这种方法存在主观性强、效率低下的问题，且难以满足大规模种植的需求。随着计算机视觉和机器学习技术的发展，基于这些技术的自动化病虫害识别系统成为可能。这些系统通过分析棉花叶片、果实和茎部的图像，能够自动识别病虫害的迹象，从而帮助农民及时采取相应的防治措施，提高棉花产量和质量。

近年来，深度学习技术在图像识别领域取得了显著进展，特别是在卷积神经网络的应用上。这些技术可以有效地从复杂的图像数据中提取特征，进行准确的分类和识别。因此，设计与实现基于深度学习的棉花病虫害识别系统具有重要的理论意义和应用价值。例如，利用迁移学习的方法，可以将大规模图像数据集上预训练的深度学习模型应用于棉花病虫害识别任务，从而提高模型的泛化能力和识别准确率。

此外，结合物联网（IoT）技术，可以实现病虫害识别系统的实时监控和远程管理。通过部署在田间的传感器和摄像头，收集棉花生长的各种数据，然后通过无线网络传输到云端或本地服务器进行处理和分析。这样不仅可以实时监测棉花的生长状况和病虫害发生情况，还可以根据分析结果智能地调整灌溉、施肥和喷药等农业管理措施，从而提高农业生产的智能化水平。

总之，棉花病虫害的自动化识别和防治对于保障全球棉花产业的健康发展具

有不可忽视的作用。通过结合深度学习、计算机视觉和物联网等先进技术，可以有效地提高病虫害识别的准确性和防治的及时性，从而提高棉花产量和质量，推动农业的可持续发展。未来的研究应当更加注重系统的实用性和可扩展性，以及如何将这些技术更好地融入到农业生产实践中，为农业现代化和全球粮食安全做出更大的贡献。

1.2 国内外研究现状

棉花病虫害识别系统的研究现状可以从国内外两个方面来概述。

国内学者侯发东等^[1]利用卷积神经网络对棉花叶部病虫害进行自动识别研究。这种方法通过训练神经网络模型，能够快速准确地识别出棉花病虫害的种类，并给予及时准确的防治。YALIKUN Shawuti 等^[2]研究了基于 Logistic 算法与多光谱遥感影像的棉花虫害监测方法。通过无人机获取棉田多光谱遥感影像，并结合受虫害棉花光谱特征，构建 Logistic 回归模型，实现了对棉花虫害的有效识别和监测。国内研究者^[3]通过改进 AlexNet 模型，并结合数据增强技术，利用 PlantVillage 大数据集训练得到预训练模型，再使用棉花病虫害数据进行微调，提高了棉花叶部病虫害图像的分类准确率。

国际上，机器视觉检测技术在棉花病虫害识别方面的应用日益成熟。这些系统能够快速获取大量信息并自动处理，容易与设计信息以及加工控制信息集成，提高了识别的效率和准确性。国际上的研究者也在探索使用深度学习模型，如 VGG-19 和 GoogLeNet Inception v2 等，来提高棉花病虫害图像的分类效果。通过迁移学习的方法，可以将其他领域训练好的模型应用到棉花病虫害识别上，从而提高识别的准确率。^[4]此外，多光谱和高光谱遥感技术也被广泛应用于棉花病虫害的监测和识别。^[5]这些技术可以提供更丰富的光谱信息，有助于提高病虫害识别的精度。国际组织和农业研究机构也在制定综合的棉花病虫害防控技术方案，这些方案不仅包括病虫害的识别技术，还涉及预防、监测和治理等多个方面，形成了一套完整的病虫害管理策略。

综上所述，无论是国内还是国际，棉花病虫害识别系统的研究都在不断进步，新技术的应用和新方法的开发都在推动着这一领域的发展。特别是在人工智能和机器学习技术的推动下，棉花病虫害的自动化识别和监测正在变得更加高效和准确。

1.3 主要研究内容

本文旨在探讨和改进当前棉花病虫害检测识别技术，以解决现有研究中存在的准确性和实用性问题。棉花作为一种重要的经济作物，其健康生长对农业生产和经济发展至关重要。然而，病虫害的侵害严重影响了棉花的产量和质量，因此，开发一种高效、准确的病虫害检测系统显得尤为重要。本文首先对现有的病虫害识别技术进行了综述，分析了它们的优缺点，并在此基础上提出了改进的想法。通过对主流病虫害识别神经网络模型的对比分析，本文选择了适合于本研究的神经网络模型。考虑到用户在实际拍摄过程中可能遇到的各种问题，本文采用了实验室现有的叶片图片数据集，利用卷积神经网络进行叶片检测，并针对性地对检测网络进行了改进，以提高检测效果。

在棉花病虫害识别的核心环节，本文采用了 MobileNetV2 网络模型，这是一种专为移动和嵌入式视觉应用设计的轻量级深度神经网络。MobileNetV2 通过使用深度可分离卷积来减少模型的参数数量和计算复杂度，从而实现了在保持较高识别准确性的同时，降低了模型的运行资源消耗。^[6]本文对 MobileNetV2 模型进行了进一步的改进，通过调整网络结构和超参数，以及采用数据增强技术，提高了模型对病虫害的识别准确性和泛化能力。这些改进使得模型不仅能够在实验室环境下表现良好，而且能够在实际的复杂环境中实现高效、准确的病虫害识别，满足了用户对于可靠性和实时性的要求。

为了实现一个用户友好、响应迅速的棉花病虫害识别系统，本文设计了一个基于浏览器/服务器（B/S）模式的系统架构。系统前端采用 Vue 框架，这是一种基于 JavaScript 的渐进式框架，能够高效地构建用户界面，并提供良好的用户体验。通过 Vue 框架，用户可以轻松上传田间拍摄的棉花叶片图片，并实时查看识别结果。系统后端采用 Flask 框架，这是一种使用 Python 编写的轻量级 Web 应用框架，它提供了丰富的库和工具，使得开发复杂的后端逻辑变得简单快捷。后端负责接收前端传来的图片，调用经过训练的病虫害识别模型进行处理，并返回识别结果。整个系统的架构设计考虑了扩展性和维护性，便于未来功能的增加和技术的更新。通过这种前后端分离的设计，本文提出的系统不仅能够提供高效、准确的病虫害检测服务，还能够适应不同设备和平台，满足更广泛的用户需求。

1.4 论文结构安排

本文内容共分为五章，每章的安排如下所述：

第一章：绪论。首先介绍了棉花病虫害识别系统的研究背景及意义，然后以棉花病虫害的两种研究类别为主线介绍了国内外研究现状，接着阐述了本文的主要研究内容，最后说明了论文的组织架构。

第二章：相关理论及技术基础。本章详细阐述了本文涉及到的相关理论与技术基础。

第三章：基于 MobileNetV2 改进的棉花病虫害识别算法。首先介绍了本文算法的整体框架，然后按模块详细阐述了算法是如何设计的，最后通过对比实验以及实验结果验证了本文所提出的算法的有效性，并对实验结果进行了分析。

第四章：系统的设计与实现。首先对系统进行了需求分析；然后介绍了本文系统的设计，包括系统的架构设计以及功能模块设计；接着说明了系统的各功能是如何实现的，并且进行了功能演示；最后进行了系统的测试。

第五章：结论与展望。本章总结了全文的研究内容，并对本文研究的不足之处进行了分析，最后针对不足之处展望了未来的研究工作。

2 相关理论与技术

2.1 卷积神经网络

卷积神经网络是一种深度学习模型，特别适用于处理具有网格结构的数据，如图像（2D 网格）和时间序列数据（1D 网格）。CNN 在图像识别、视频分析、自然语言处理等领域取得了显著的成就，是计算机视觉领域的核心技术之一。

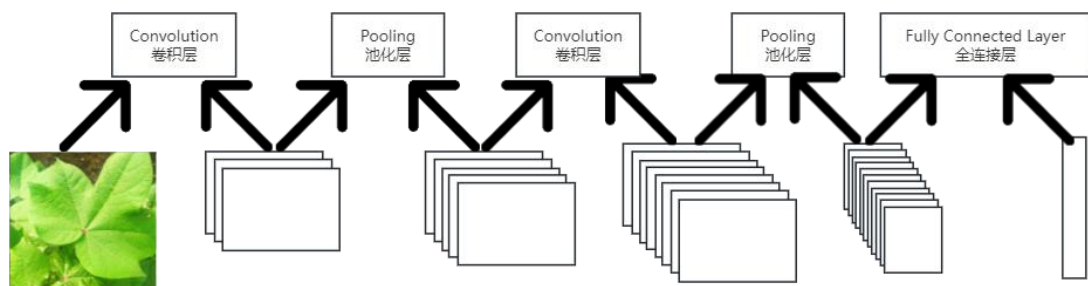


图 2-1 卷积神经网络基本结构示意图

CNN 的核心思想是利用卷积层自动从输入数据中学习空间层次结构的特征。如图 2-1 所示，这些特征对于识别图像中的对象、形状和纹理等视觉模式至关重要。CNN 的主要组成部分包括：

(1) 卷积层（Convolutional Layer）：通过卷积操作提取输入数据的局部特征。卷积层中的每个神经元只与输入数据的一个局部区域（称为感受野）相连，这样可以减少参数数量并提高计算效率。卷积核（或滤波器）在输入数据上滑动，计算局部区域的加权和，生成特征图（Feature Map）。

(2) 激活函数（Activation Function）：通常在卷积层之后应用非线性激活函数，如 ReLU（Rectified Linear Unit），以增加模型的非线性表达能力，使其能够学习更复杂的特征。

(3) 池化层（Pooling Layer）：也称为下采样层，用于减少特征图的空间尺寸，从而减少参数数量和计算量。池化操作有助于提取更抽象的特征，并增强模型对位置变化的鲁棒性。

(4) 全连接层（Fully Connected Layer）：在多个卷积和池化层之后，全连接层将学习到的特征映射到最终的输出，如分类任务中的类别标签。全连接层的

每个神经元都与前一层的所有激活值相连。

(5) 丢弃层 (Dropout Layer)：在训练过程中随机丢弃一部分神经元的激活值，以防止过拟合，增强模型的泛化能力。

CNN 的优势在于其能够自动并有效地学习空间层次结构的特征，无需人工设计特征提取器。此外，卷积层的参数共享机制使得模型在处理图像时具有平移不变性，即无论目标对象在图像中的位置如何变化，CNN 都能够识别出来。

随着深度学习技术的发展，CNN 的结构也在不断演进，出现了许多变体和改进，如 AlexNet、VGGNet、ResNet 等，这些模型在不同的基准测试中取得了优异的性能。

2.2 经典卷积神经网络模型研究

2.2.1 DenseNet121

DenseNet (Densely Connected Convolutional Networks) 是一种卷积神经网络架构，2017 年由 Gao Huang 等人^[7]提出。该网络的核心思想是密集连接，即每一层都接收其前面所有层的输出作为输入。DenseNet121 是该家族中的一个特定模型，其中 121 表示网络的总层数。

DenseNet121 的主要特点如下：

(1) 密集连接 (Dense Connection)：在一个 Dense Block 内，第 i 层的输入不仅仅是第 $i-1$ 层的输出，还包括第 $i-2$ 层、第 $i-3$ 层等所有之前层的输出。这种密集连接方式促进了特征的重用。

(2) 参数效率：由于特征在网络中得以重复使用，DenseNet 相较于其他深度网络模型（如 VGG）通常需要更少的参数来达到相同（或更好）的性能。

(3) 特征复用与强化：密集连接方式也促进了梯度的反向传播，使得网络更容易训练。同时，低层特征能被直接传播到输出层，因此被更好地强化和利用。

(4) 过拟合抑制：由于有更少的参数和更好的参数复用，DenseNet 很适合用于数据集较小的场合，能在一定程度上抑制过拟合。

(5) 增加网络深度：由于密集连接具有有利于梯度反向传播的特性，DenseNet 允许构建非常深的网络。

(6) 计算效率：虽然有很多连接，但由于各层之间传递的是特征图（而不是参数或梯度），因此在计算和内存效率方面表现得相对较好。

(7) 易于修改和适应: DenseNet 架构很容易进行各种修改, 以适应不同的任务和应用需求。

DenseNet121 在很多计算机视觉任务中都表现出色, 例如图像分类、目标检测和语义分割等。因其出色的性能和高效的参数使用, DenseNet121 常被用作多种视觉应用的基础模型。

2.2.2 ResNet18

残差神经网络 (ResNet) 是由微软研究院的何恺明、张祥雨、任少卿、孙剑等人提出的。ResNet 在 2015 年的 ILSVRC (ImageNet Large Scale Visual Recognition Challenge) 中取得了冠军。残差神经网络的主要贡献是发现了“退化现象 (Degradation)”, 并针对退化现象发明了“快捷连接 (Shortcut connection)”, 极大的消除了深度过大的神经网络训练困难问题。^[8]

ResNet18 的基本含义是, 网络的基本架构是 ResNet, 网络的深度是 18 层。但是这里的网络深度指的是网络的权重层, 也就是包括池化, 激活, 线性层。而不包括批量化归一层, 池化层。

2.2.3 ResNet50

ResNet-50, 全称为 Residual Network with 50 layers, 是一种深度卷积神经网络, 由微软研究院的 Kaiming He 等人在 2015 年提出。它是残差网络 (ResNet) 系列中的一个变体, 因其具有 50 层网络结构而得名。ResNet-50 在当年的 ImageNet 大规模视觉识别挑战赛 (ILSVRC) 中取得了突破性的成绩, 极大地推动了深度学习领域的发展。^[9]

ResNet-50 的核心概念是残差学习, 它解决了随着网络层数增加而导致的训练困难问题, 即所谓的“梯度消失”和“梯度爆炸”问题。残差学习的思想是让网络学习输入和输出之间的残差 (即差异), 而不是直接学习映射关系。这样做的好处是可以通过“跳跃连接” (skip connections) 或“捷径连接” (shortcut connections) 将输入直接添加到后面的层, 从而使得网络可以更容易地学习到恒等映射 (identity mapping), 即输出与输入相同。

ResNet-50 因其出色的性能和可扩展性, 在图像识别、物体检测、语义分割等多个计算机视觉任务中得到了广泛应用。它不仅在学术界受到重视, 在工业界也被广泛使用。

2.2.4 VGG16

VGG16 是一种流行的卷积神经网络架构，^[10]由牛津大学的视觉几何组（Visual Geometry Group）在 2014 年提出，并在 2014 年的 ImageNet 大规模视觉识别挑战赛（ILSVRC）中取得了优异的成绩。VGG16 是 VGG 系列模型中的一种，数字 16 代表其卷积层和全连接层的总数。VGG16 的核心特点有：

(1) 层数结构：VGG16 包含 13 个卷积层和 3 个全连接层，以及相应的池化层和归一化层。

(2) 小卷积核：VGG16 使用 3×3 的小卷积核，这与当时其他流行的网络结构（如 AlexNet 和 GoogLeNet）使用更大的卷积核不同。小卷积核的使用使得网络能够通过堆叠更多层来捕捉更复杂的特征。

(3) 连续的卷积层：VGG16 的特点是连续堆叠的卷积层，每个卷积层后面紧跟着一个激活函数（ReLU），然后是池化层。这种设计简化了网络结构，使得模型更加容易训练。

(4) 最大池化：VGG16 使用最大池化（Max Pooling）来降低特征图的空间维度，减少计算量，同时保留重要的特征信息。

(5) 批归一化：VGG16 在每个卷积层之后使用了批归一化（Batch Normalization），这有助于加速训练过程并减少过拟合。

VGG16 在 ImageNet 2014 的挑战赛中取得了第二名的成绩，其 top-5 错误率约为 7.5%。尽管它在性能上可能不如后来的一些模型（如 ResNet 系列），但 VGG16 因其简洁的架构和良好的性能，成为了深度学习和计算机视觉领域的一个重要里程碑。VGG16 因其优秀的特征提取能力，在图像识别、物体检测、图像分割等多种计算机视觉任务中得到了广泛应用。它也被用作许多预训练模型的基础，通过迁移学习的方法在特定任务上进行微调，以提高模型的性能。

VGG16 的成功不仅在于其在竞赛中的表现，还在于其对后续研究的启发。它的设计影响了后续许多网络架构的发展，特别是在卷积层堆叠和特征提取方面。VGG16 也是许多后续研究和比较的基准模型，对于理解深度学习模型的工作原理和性能有着重要的意义。

总的来说，VGG16 是一个在深度学习领域具有标志性的模型，它的设计和性能为后续的研究和应用提供了宝贵的参考。

2.3 系统开发相关技术

2.3.1 PyTorch 深度学习框架

在 2017 年，Facebook 的研究团队推出了 PyTorch，这是一个免费且开源的框架，具备 GPU 加速的能力。该框架的核心运算单元是张量（Tensor），它使得处理大规模矩阵运算和复杂数学表达式变得简单高效。与 Tensorflow 采用静态计算图并在模型构建后无法更改不同，PyTorch 提供了动态计算图，允许开发者根据任务需求实时调整代码，从而享有更大的灵活性。

PyTorch 的多项优势使其在深度学习框架中脱颖而出：

它不仅运行效率高，而且设计上具有很高的灵活性。多项实验结果显示，PyTorch 的计算速度优于 Keras 等其他框架。PyTorch 采用 Python 语言编写，将许多神经网络中常用的公式和算法封装成易于调用的类。例如，`torch.nn.Linear()` 类提供了线性变换功能，用户只需实例化该类即可使用，大大简化了编程过程。由于 Python 语言的简洁性，PyTorch 的源码更易于阅读和理解，特别是对于 Java 和 C 语言来说。此外，PyTorch 提供了详尽的文档，便于用户学习和理解他人的代码，非常适合深度学习领域的新手。PyTorch 拥有一个活跃的社区论坛，用户可以在此交流和学习，共同解决深度学习过程中遇到的问题。

基于上述优势，本文选择了 PyTorch 作为模型构建和训练的框架。

2.3.2 Vue 框架

Vue 是一套用于构建用户界面的渐进式的 JavaScript 框架，由于其具有体积小、更高的运行效率、双向数据绑定以及生态丰富、学习成本低等诸多优点而越发受到网站开发人员的喜爱，成为了前端主流框架之一。

Vue 因其具有高效多用途的特点且能够帮助创建易维护性的代码库而越来越受到前端开发人员所推崇。Vue 是渐进式的 JavaScript 框架，也就是说，一旦已经有了现成的服务端应用，就可以将 Vue 以模块的方式嵌入到应用当中从而可以为用户带来更加丰富的交互体验。和其它框架一样，Vue 允许开发人员将一个网页分割成可以复用的组件，每个组件都包含独立的 HTML（HyperText Markup Language）、CSS（Cascading Style Sheets）、JavaScript，以用来渲染网页中相应的地方。如果需要构建一个大型的应用，可能需要将东西分割成为各自的组件和文件，使用 Vue 的命令行工具，使快速初始化一个真实的工程变得非常简单。

2.4 数据集和评价指标

2.4.1 数据集

通过国家重大科技专项子课题，多模态信息层级融合技术（2022ZD0115802）获取数据集：该数据集有农作物棉花的 6 种病虫害，分别是蚜虫（Aphids）、蚜虫（Army worm）、白叶枯病（Bacterial Blight）、健康的叶子（Healthy leaf）、白粉病（Powdery Mildew）、靶点（Target spot）每一类病虫害对应一个文件夹，棉花疾病有 6 个文件夹。每个文件夹包含疾病图像的原始 JPG 文件，以及疾病图像的真实标签。数据集共有 4549 张高质量的图像数据。

2.4.2 评价指标

在本研究中，选取了 TOP1 准确率作为评估模型性能的指标。所谓 TOP1 准确率，即指模型识别出的结果中，概率最高的类别与实际正确的类别相一致的情况。

该指标反映了模型在所有样本中正确分类的比例，其计算公式详细展示。

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2-1)$$

具体而言，真正类（TP）表示模型正确地将正类样本识别为正类；真负类（TN）表示模型准确地将负类样本归类为负类；假正类（FP）则指模型错误地将负类样本判定为正类；而假负类（FN）是指模型未能正确识别正类样本，将其误判为负类。

在对测试集进行评估时，本文直接计算模型在所有测试图像上正确识别的概率，以此作为评价模型性能的标准。

2.5 本章小结

本章内容作为深入理解卷积神经网络的重要基础，首先对卷积神经网络的核心组成和工作原理进行了简洁而全面的概述。卷积神经网络是一种深度学习算法，它通过模拟人类视觉系统的处理机制，能够在图像识别、分类和分析等任务中取得卓越的性能。

在介绍了卷积神经网络的基本概念之后，本章深入探讨了几种经典的卷积神经网络模型，包括 Densenet121、ResNet18、ResNet50 和 VGG16。每个模型都有其独特的设计理念和优势，例如 Densenet121 以其密集连接的特点提高了网络的信息流和梯度传播效率；ResNet 通过引入残差学习解决了深层网络训练的难题；而 VGG16 则因其简单而有效的网络结构在图像识别领域具有广泛的应用。

进一步地，本章对搭建这些网络模型所需的数据集进行了详细的说明。数据集的选择和准备对于模型训练的效果至关重要。在数据分析方面，本章阐述了评价模型性能的关键指标——准确率。这个评价指标为模型的性能提供了量化的衡量标准，有助于研究人员了解模型的强项和弱点，从而进行针对性的优化和改进。

最后，本章介绍了在本研究中使用的 PyTorch 和 Vue 框架。PyTorch 是一个强大的开源机器学习库，它提供了丰富的 API 和工具，使得设计和实现复杂的卷积神经网络变得简单快捷。Vue 框架则是一种用于构建用户界面的渐进式 JavaScript 框架，它能够与 PyTorch 无缝集成，为模型的可视化和交互提供了强大的支持。

综上所述，本章内容为后续的研究工作奠定了坚实的理论基础，不仅涵盖了卷积神经网络的基础知识和经典模型，还涉及了数据集的准备、评价指标的选择以及实现工具的应用，为读者深入探索和应用卷积神经网络提供了全面的指导。

3 棉花病虫害识别算法设计

3.1 引言

本章的核心目标是构建一个高效且适用性强的网络模型，以为后续的实际应用系统提供坚实的技术支撑。为了实现这一目标，文章选择了业界广泛认可的 MobileNetV2 模型作为基础模型。MobileNetV2 是一种专为移动和嵌入式设备设计的深度学习模型，它通过使用深度可分离卷积来减少计算量和模型大小，从而在保持较高准确度的同时实现了高效的性能。

在此基础上，为了进一步提升棉花病虫害检测的准确性和模型的实用性，本章对 MobileNetV2 模型进行了一系列的改进。这些改进可能包括但不限于调整网络结构、引入新的激活函数、优化训练策略等，旨在使模型更好地适应棉花病虫害检测的特殊需求。例如，通过增加或减少网络层的数量，可以调整模型的深度和复杂度，以适应不同难度的检测任务；通过引入注意力机制，可以增强模型对病虫害特征的识别能力。

为了验证这些改进的有效性，本章设计了一系列的实验对比分析。这些实验在本研究所采集的棉花叶片数据集上进行了测试，并且与本研究改进的模型进行了性能比较。通过精确的定量分析，如准确率、LOSS 损失函数曲线、参数量等指标，可以全面评估改进措施对模型性能的影响，以及模型在实际应用中的潜在价值。

3.2 MobileNetV2 模型整体框架

MobileNetV2 是一种为移动和嵌入式设备设计的高效深度神经网络架构，它在保持较高准确性的同时显著降低了计算和内存需求。该网络的核心特点是采用了倒置残差结构和线性瓶颈，这些设计使得 MobileNetV2 在多种任务上表现出色，同时保持了模型的轻量级。^[11] MobileNetV2 的网络结构主要由以下几个部分组成：

(1) 初始层：网络以一个 32 个滤波器的全卷积层开始，这一层负责处理输入图像并提取初步的特征。

(2) 倒置残差结构：MobileNetV2 采用了倒置残差结构，与传统的残差结构

不同，它的快捷连接位于瓶颈层之间，而不是在扩展层之间。这种设计有助于更有效地利用内存和计算资源。

(3) 瓶颈层：每个残差块包含一系列瓶颈层，这些层首先通过 1×1 卷积将特征图的维度扩展到更高的维度，然后通过轻量级的 3×3 深度可分离卷积进行特征过滤，最后再通过另一个 1×1 卷积将特征图维度压缩回原来的维度。瓶颈层的设计旨在减少参数数量和计算复杂度，同时保持特征的丰富性。

(4) 扩展因子：MobileNetV2 引入了扩展因子的概念，用于控制瓶颈层和扩展层之间的维度变化。通过调整扩展因子，可以灵活地改变网络的容量，以适应不同的性能需求。

(5) 激活函数：MobileNetV2 使用了 ReLU6 作为非线性激活函数，这是一种专为低精度计算设计的激活函数，有助于提高网络在移动设备上的性能。

(6) 输出层：网络的最后部分为全连接层，并且使用 SoftMax 激活函数将特征映射到 $[0, 1]$ 之间，再将模型得到的特征输入到分类器中得到最终的输出类别。MobileNetV2 的设计允许通过调整输入图像的分辨率和宽度乘数来灵活地平衡准确性和性能。

此外，MobileNetV2 的内存高效推理特性使其非常适合在资源受限的环境中使用，例如在移动设备上实时图像识别和处理任务。通过这些设计，MobileNetV2 广泛应用在分类任务中，很好的平衡了分类任务所需的计算资源和精度指标。MobileNetV2 模型的残差块如图 3-1 所示。

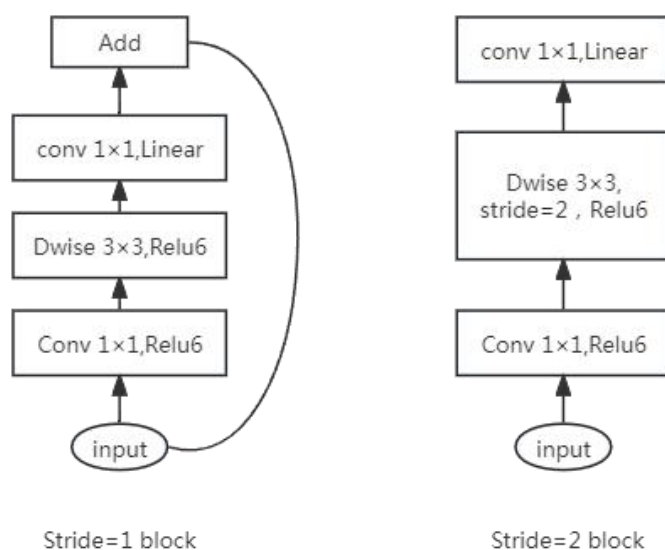


图 3-1 MobileNetV2 模型的残差块

3.3 基于 MobileNetV2 的改进型棉花病虫害识别算法

3.3.1 改进的 MobileNetV2 模型整体框架

本文模型以 MobileNetV2 为网络基础进行改进，在使用时，模型最后的输出会返回最大概率的类别，然后返回在 Web 网页端显示。为了提高模型的性能，本文在 MobileNetV2 网络的基础上加入 EMA 注意力机制，即在每一个 Stride=2 块的末尾加入 EMA 注意力模块如图。提取不同通道以及不同区域的权重信息，进行权重的调整来着重关注关键信息，加入 EMA 注意力模块后的网络结构图如图 3-2 所示。

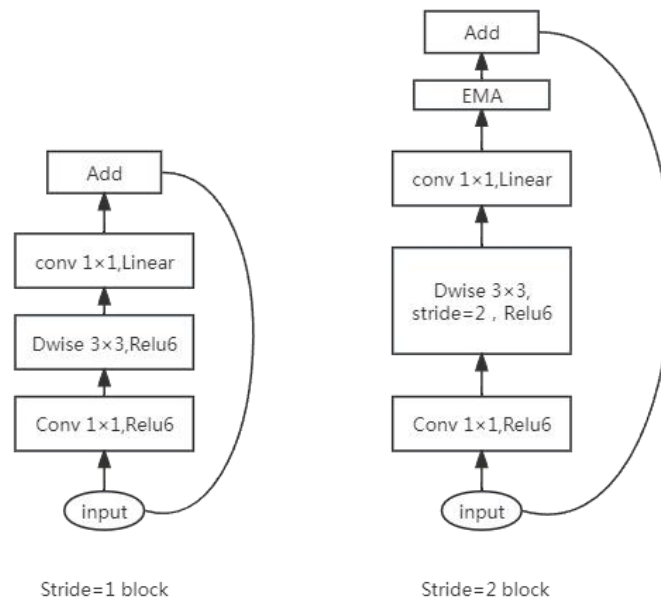


图 3-2 基于 MobileNetV2 改进后模型的残差块

3.3.2 注意力模块

注意力机制 (Attention Mechanism) 是机器学习中的一种数据处理方法，广泛应用于自然语言处理、图像识别以及语音识别等各种不同类型的机器学习任务中。注意力机制对不同信息的关注程度（重要程度）由权值来体现，注意力机制可以视为查询矩阵 (Query)、键 (key) 以及加权平均值构成了多层感知机^[12] (Multilayer Perceptron, MLP)。

注意力的思想，类似于寻址。给定 Target 中的某个元素 Query，通过计算 Query 和各个 Key 的相似性或相关性，得到每个 Key 对应 Value 的权重系数，然后对 Value 进行加权求和，即得到最终的 Attention 数值。所以，本质上 Attention

机制是 Source 中元素的 Value 值进行加权求和，而 Query 和 Key 用来计算对应 Value 的权重系数。

(1) EMA

EMA (Efficient Multi-scale Attention, EMA) 是一种无需降维的高效多尺度注意力，基于跨空间学习的高效多尺度注意力模块，由 ICASSP2023 推出，效果优于 ECA、CBAM、CA 等注意力模块。EMA 模块专注于保留每个通道的信息，并减少计算开销，通过将通道维度分组为多个子特征，并使空间语义特征在每个特征组内分布均匀。具体来说，除了对全局信息进行编码以重新校准每个并行分支中的信道权重外，还通过跨维交互方法进一步聚合了两个并行分支的输出特征。

EMA 模块^[13]的核心思想是在保持通道信息的同时，通过并行分支编码全局信息，并重新校准每个分支中的通道权重。此外，EMA 通过跨维度交互方法进一步聚合两个并行分支的输出特征。通过在常用基准数据集上的广泛实验，如 CIFAR100 图像分类，以及 MS COCO 和 VisDrone2019 数据集上的目标检测，结果表明 EMA 在不改变网络深度的情况下，显著优于其他几种最近的注意力机制。

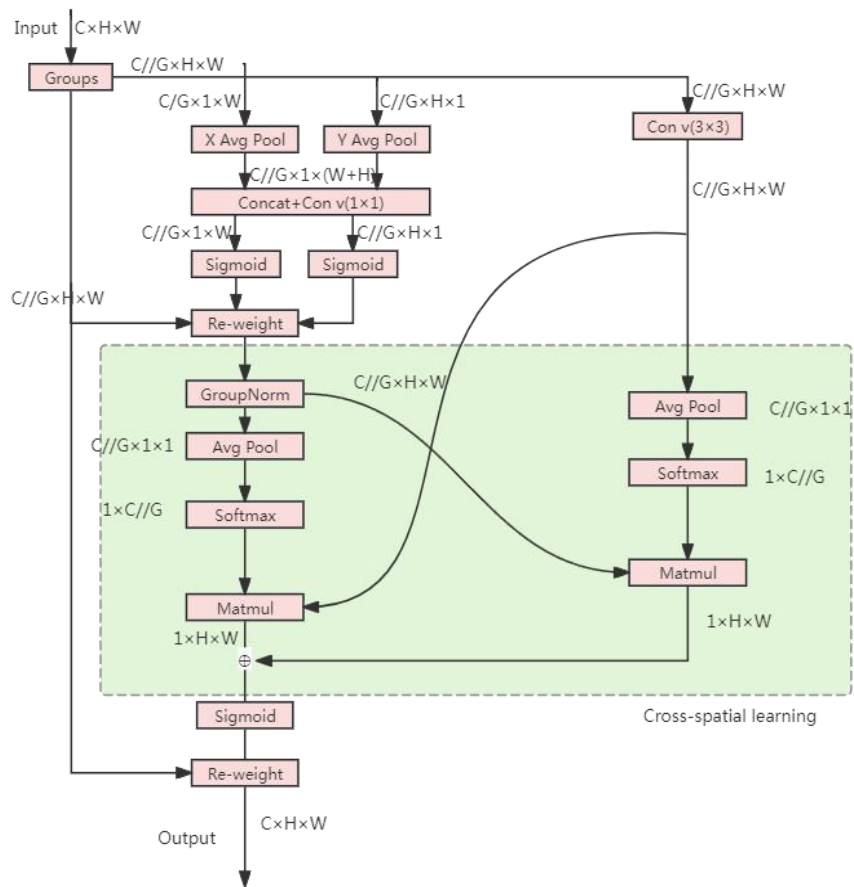


图 3-4 EMA 结构图

EMA 模块的结构如图 3-4 所示，它通过 1×1 卷积提取 CA 中的共享部分，并将其作为 EMA 中的 1×1 分支。对于任何给定的输入特征图，EMA 将输入沿通道维度划分为多个子特征，并通过全局平均池化操作沿两个空间方向编码通道注意力。此外，EMA 还通过 3×3 卷积分支捕捉多尺度特征表示。

总结而言，EMA 模块通过其灵活和轻量级的特性，易于集成到不同的计算机视觉任务中。尽管本文主要关注图像分类和目标检测，但 EMA 的方法也适用于更广泛的应用，如语义分割，并可以与其他 CNN 模型结合使用，以提升特征表示能力。

3.3.3 损失函数

本文使用的损失函数为 FocalLoss 损失函数，FocalLoss 是一种用于解决类别不平衡问题的损失函数，在目标检测和语义分割等任务中得到了广泛应用，它与交叉熵损失函数同等对待难易样本的方式不同，它会聚焦于损失更大的样本进行训练。传统的交叉熵损失函数 (Cross-entropy Loss) 在处理类别不平衡问题时，容易受到多数类别的影响，导致模型对少数类别的分类效果较差。FocalLoss 通过引入一个可调参数 γ ，对少数类别的错误分类进行更加强烈的惩罚，从而提高模型对少数类别的分类能力。

$$FL(pt) = -\alpha t(1 - pt)^{\gamma} \log(pt) \quad (3-1)$$

其中：

pt 是模型对于正确类别的预测概率。当模型对一个样本分类正确时， pt 接近 1；分类错误时， pt 接近 0。

αt 是平衡类别权重的系数，用于调整不同类别的损失贡献。在处理类别不平衡问题时，可以为不同类别设置不同的 αt 。

γ 是调节模型对难易样本关注程度的调节因子，通常设置为 2 或 5。 γ 的引入使得模型对于预测概率高的样本赋予更低的权重，从而更加关注那些预测概率低的样本。

$\log(pt)$ 是交叉熵损失的一部分，用于衡量模型预测概率与实际标签之间的差异。

3.4 实验结果及分析

3.4.1 实验参数设置

在实验室服务器进行训练，采用 PyTorch 深度学习框架，安装 CUDA 加速模型计算，详细版本信息如表 3-1 所示。

表 3-1 实验参数设置表

环境	名称/型号	参数/版本号
硬件环境	CPU	英特尔第十一代酷睿 i5-1135G7
	GPU	Nvidia GeForce MX450
	OS	WINDOWS10
	Python 版本	3.9
软件环境	Pytorch 版本	1.7
	CUDA	Cuda11.0.2

3.4.2 对比算法分析

本文以棉花病虫害图像为研究对象，每种病虫害选择均是接近到了 400 张图像，共接近 2400 张图像构建训练集图像数据库；而剩余的 240 多张照片组成测试集图像，如表 3-2 所示。

表 3-2 棉花病虫害图像统计

类别名称	测试集张数	训练集张数
蚜虫 (Aphids)	39	400
蚜虫 (Army worm)	40	400
白叶枯病 (Bacterial Blight)	40	400
健康的叶子 (Healthy leaf)	39	400
白粉病 (Powdery Mildew)	38	400
靶点 (Target spot)	41	400

将改进后的算法与五个经典算法 (Densenet121、ResNet18、ResNet50、VGG16 和 MobileNetV2) 分别在训练集和测试集上进行损失函数和 ACC 准确率比较。

(1) Densenet121

通过实验可以得出算法的参数量是 29.13M。实验结果如图 3-5 所示。

从 ACC 曲线图可以看出，随着时间的推移（或迭代次数的增加），train acc

从 1.00 开始逐渐下降到 0.92。这表明模型在初始阶段表现完美，但随着训练的深入，准确率开始下降，这可能是过拟合的迹象，即模型在训练数据上学习得太好，以至于无法很好地泛化到新的数据上。Val acc 也是从 0.98 开始下降，最终稳定在 0.94 左右。这表明模型在验证集上的表现也在下降，但下降幅度相对较小。

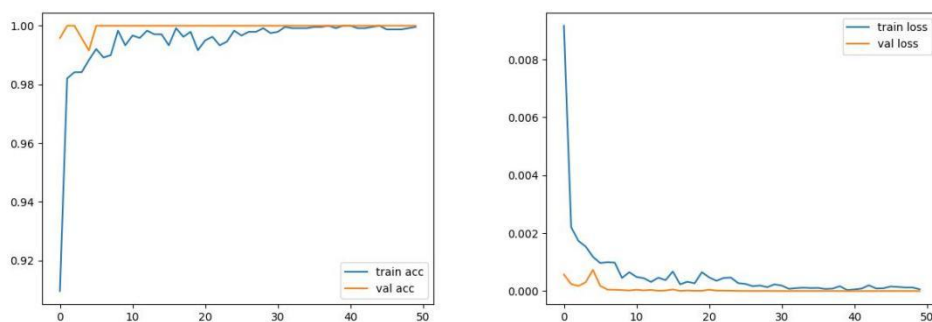


图 3-5 Densent121 的准确率曲线图和 LOSS 损失函数图

从 LOSS 损失函数图中可以看出，训练损失从 0.008 开始逐渐下降，直到趋近于 0。这表明模型在训练过程中逐渐学习到了数据中的模式，并在预测任务上表现得越来越好。损失值的下降趋势说明模型的参数更新和学习策略在起作用，模型的性能在提升。验证损失的变化趋势与训练损失类似，也是从较高的值开始下降，但下降幅度相对较小，最终稳定在 0.002 左右。这表明模型在未参与训练的数据上也能保持较好的泛化能力，即模型不仅能在训练集上表现良好，也能在新的数据上做出准确的预测。

(2) ResNet18

通过实验可以得出算法的参数数量是 43.73M。实验结果如图 3-6 所示。




图 3-6 ResNet18 的准确率曲线图和 LOSS 损失函数图

从 ACC 曲线图中可以看出，训练准确率从 1.00 开始逐渐下降，直到 0.90。

这种下降趋势可能表明模型在初始阶段对训练数据的拟合过于完美，但随着迭代次数的增加，模型开始过拟合，导致在训练集上的准确率下降。过拟合是机器学习中的一个常见问题，指的是模型在训练数据上表现很好，但在新的、未见过的数据上表现不佳。验证集通常是从原始数据中分出的一部分，不参与训练过程，用来评估模型的泛化能力。从图中可以看出，验证准确率从 0.88 开始，随着迭代次数的增加，呈现出一种波动下降的趋势，最终接近 0.92。这表明模型在未参与训练的数据上的表现也在逐渐变差，这同样可能是过拟合的迹象。

从图中可以看出，训练准确率和验证准确率之间存在一定的差距，这是正常的，因为训练集是用来训练模型的，而验证集用来评估模型的泛化能力。然而，当训练准确率远高于验证准确率时，这通常意味着模型在训练集上过拟合，而没有很好地捕捉到数据的一般规律。

从 LOSS 损失函数图中可以看出，训练损失从 0.012 开始，随着迭代次数的增加，损失值逐渐下降，最终趋近于 0。这表明模型在训练过程中逐渐学习并改进其预测能力，损失值的下降趋势说明模型的参数更新和学习策略在起作用，模型的性能在提升。从图中可以看出，验证损失从 0.010 开始，随着迭代次数的增加，损失值也呈现出下降趋势，但下降幅度相对较小，最终稳定在 0.004 左右。这表明模型在未参与训练的数据上也能保持较好的泛化能力，即模型不仅能在训练集上表现良好，也能在新的数据上做出准确的预测。

从图中可以看出，训练损失和验证损失都呈现出明显的下降趋势，这是一个积极的迹象，表明模型在训练过程中正在学习并改进其预测能力。然而，需要注意的是，尽管损失值在下降，但如果下降速度过快或损失值过低，也可能存在欠拟合的风险，即模型没有足够地学习数据中的模式。

(3) ResNet50

通过实验可以得出算法的参数量是 94M。实验结果如图 3-7 所示。

从 ACC 曲线图中可以看出，随着时间的推移（或迭代次数的增加），训练准确率逐渐下降，从 1.00 降至 0.90。这种下降可能是由于模型在训练过程中逐渐学习到了数据的特征，但也可能因为过拟合导致在训练集上的表现下降。随着时间的推移，验证准确率呈现出波动下降的趋势，从 0.98 降至 0.92。这种波动可能是由于模型在训练过程中对训练数据的拟合和泛化能力的变化所致。

从 LOSS 损失函数图中可以看出，开始时，训练损失较高，这可能是因为模

型在初始阶段还没有学习到有效的特征表示。随着训练的进行，训练损失逐渐下降，这表明模型在不断学习并提高了对训练数据的拟合能力。训练损失的下降趋势在迭代过程中逐渐趋于平缓，这可能意味着模型正在接近其在训练集上的最佳性能。验证损失的初始值相对较低，这可能意味着模型在开始时对未见过的数据有着不错的泛化能力。与训练损失类似，验证损失也随着时间的推移而降低，但下降的速度可能比训练损失慢，这可能是因为在训练过程中逐渐学习到了更复杂的特征，而这些特征在验证集上的表现可能不如在训练集上。




图 3-7 ResNet50 的准确率曲线图和 LOSS 损失函数图

从图中可以看出，训练和验证损失的值都在 0 到 0.008 之间，这是一个相对较低的损失值范围，表明模型在训练过程中表现良好。损失值的下降趋势表明模型在逐渐学习并减少预测误差。

(4) VGG16

通过实验可以得出算法的参数量是 105.16M。实验结果如图 3-8 所示。




图 3-8 VGG16 的准确率曲线图和 LOSS 损失函数图

从 ACC 曲线图中可以看出，随着迭代次数的增加，训练准确率逐渐下降，从 1.00 降至 0.90。这种下降可能是由于模型在训练过程中逐渐学习到了数据的特征，但由于某些原因（如过拟合、学习率设置不当等），模型在训练集上的表

现反而变差了。初始准确率为 0.98，这表明模型在训练开始时在未见过的数据上有着很好的表现。随着迭代次数的增加，验证准确率也呈现出下降趋势，从 0.98 降至 0.88。这可能是由于模型在训练过程中的泛化能力出现了问题，或者是由于训练集和验证集之间的数据分布不一致导致的。从图中可以看出，无论是训练准确率还是验证准确率，都随着迭代次数的增加而下降，这通常不是一个好的信号，因为它意味着模型的性能在下降。

从 LOSS 损失函数图中可以看出，初始损失值较高，这在训练开始阶段是常见的，因为模型刚开始学习，权重初始化为随机值，所以预测结果与实际标签差异较大。随着迭代次数的增加，训练损失逐渐下降，这表明模型在逐渐学习并提高了对训练数据的拟合能力。损失值的下降趋势在迭代过程中逐渐趋于平缓，这可能意味着模型正在接近其在训练集上的最佳性能。初始损失值较训练损失值略低，这可能意味着模型在开始时对未见过的数据有着不错的泛化能力。

从图中可以看出，训练和验证损失的值都在 0.012 到 0.000 之间，这是一个相对较低的损失值范围，表明模型在训练过程中表现良好。损失值的下降趋势表明模型在逐渐学习并减少预测误差。这张图显示了 VGG16 模型在训练过程中损失值的下降趋势，这是一个积极的信号，表明模型在不断学习和改进。

(5) MobileNetV2

通过实验可以得出算法的参数数量是 9.07M。实验结果如图 3-9 所示。




图 3-9 MobileNetV2 的准确率曲线图和 LOSS 损失函数图

从 ACC 曲线图中可以看出，这张图反映了 MobileNetV2 模型在训练过程中训练集（train acc）和验证集（val acc）准确率的变化情况。MobileNetV2 是一个为移动设备优化的深度学习模型，尽管初始训练准确率异常地高，但随着迭代次数的增加，两者都出现了下降，训练准确率从 1.00 降至 0.86，验证准确率从 0.98 降至 0.84。这种下降趋势可能指示了过拟合或其他训练问题。

从 LOSS 损失函数图中可以看出,随着迭代次数的增加,训练损失逐渐下降,这表明模型在逐渐学习并提高了对训练数据的拟合能力。损失值的下降趋势在迭代过程中逐渐趋于平缓,这可能意味着模型正在接近其在训练集上的最佳性能。验证损失初始损失值略低于训练损失,为 0.014,这可能意味着模型在开始时对未见过的数据有着不错的泛化能力。从图中可以看出,训练和验证损失的值都在 0.016 到 0.000 之间,这是一个相对较低的损失值范围,表明模型在训练过程中表现良好。

(6) 基于 MobileNetV2 改进后的算法

通过实验可以得出算法的参数量是 9.25M。实验结果如图 3-10 所示。




图 3-10 基于 MobileNetV2 改进后算法的准确率曲线图和 LOSS 损失函数图

从 ACC 曲线图中可以看出,训练准确率在训练周期的前 10 个 epoch 内迅速提升,从接近 0.95 增长到接近 1.00,显示出模型在初始阶段学习能力强,能够快速适应训练数据。验证准确率的增长趋势与训练准确率相似,但稍微滞后。在前 20 个 epoch 内,验证准确率从 0.90 左右增长到接近 0.95。这表明模型在未见过的数据上也具有较好的泛化能力。训练准确率和验证准确率之间的差距较小,这表明模型没有出现拟合现象,即模型在训练数据上学到的特征也能很好地应用到验证数据上。

从 LOSS 损失函数图中可以看出,训练损失值随着训练的进行而显著下降,从 0.016 开始,逐渐减少至接近 0.000。这说明模型在训练过程中逐渐学习到了更准确的预测能力。验证损失的变化趋势与训练损失相似,从 0.014 开始下降,最终也接近 0.000。这进一步证明了模型在新数据上的预测能力得到了提升。

从准确率和损失曲线可以看出,改进后的算法能够在较短的时间内达到高准确率和低损失值,说明模型训练效率高。验证准确率的提升表明模型在未见过的数据上也能保持较高的准确率,这是机器学习中非常重要的一个特性,能够确保

模型在实际应用中的表现。训练准确率和验证准确率之间的差距较小，说明改进后的算法能够有效避免过拟合现象，这对于提高模型的实用性和可靠性至关重要。曲线的平滑下降趋势表明模型在学习过程中表现稳定，没有出现大的波动，这有助于提高模型的预测稳定性。

综上所述，基于 MobileNetV2 改进后的算法在训练效率、泛化能力、避免过拟合以及性能稳定性方面展现出了显著的优势。加进去 EMA 注意力模块以后，模型变好了，可以明显看出 LOSS 下降曲线下降的更快了，精确率上升的更快了，而且参数量要比其他五个算法的要小。这些优势使得该算法在实际应用中具有较高的可靠性和实用性，能够更好地服务于各种图像识别和分类任务。分析其中的原因，在图像分类任务中，引入注意力机制对模型性能的提升起到了关键作用。通过细致的分析可以发现，该机制有效地聚焦于图像的重要区域，并提取出关键性的特征信息。这一过程显著增强了模型对图像内容的理解与识别能力，进而优化了分类的表现。在本文提出的网络架构中，整合了注意力机制之后，模型的拟合效果得到了显著改善，分类准确度亦随之提高，展现出卓越的性能。

3.4.3 可视化结果展示

本小节主要是对算法进行可视化分析。本小节的可视化分析主要是对分类算法的性能进行评估。通过从数据集中选择上传不同类别的棉花病害图片，并使用算法对这些图片进行预测分类，可以得到预测标签和实际的真实标签进行对比。

图 3-11 是基于 MobileNetV2 改进后的算法的可视化结果，正确的结果用“☑”表示，错误的查询结果用“✕”表示。

由图 3-11 可知，Aphids 类别的图片，真实标签和预测标签都是 Aphids，预测正确，标记为 √；Army worm 类别的图片，真实标签和预测标签都是 Army worm，预测正确，标记为 √；Bacterial 类别的图片，真实标签和预测标签都是 Bacterial，预测正确，标记为 √；Blight 类别的图片，真实标签和预测标签都是 Blight，预测正确，标记为 √；Healthy leaf 类别的图片，真实标签和预测标签都是 Healthy leaf，预测正确，标记为 √；Powdery Mildew 类别的图片，真实标签是 Powdery Mildew，预测标签是 Powdery Mildew，预测正确，标记为 √；Target spot 类别的图片，真实标签和预测标签都是 Target spot，预测正确，标记为 √。







上传图片	真实标签	预测标签	预测结果
	Aphids	Aphids	<input checked="" type="checkbox"/>
	Army worm	Army worm	<input checked="" type="checkbox"/>
	Bacterial Blight	Bacterial Blight	<input checked="" type="checkbox"/>
	Healthy leaf	Healthy leaf	<input checked="" type="checkbox"/>
	Powdery Mildew	Powdery Mildew	<input checked="" type="checkbox"/>
	Target spot	Target spot	<input checked="" type="checkbox"/>

图 3-11 可视化结果展示

总体而言，模型在所有测试类别上的预测结果均为准确，这表明模型具有很高的分类性能和可靠性。通过这些准确的预测结果，可以认为模型在识别和分类棉花病虫害方面是成功的。

3.5 本章小结

本章节的研究重点是在自然生长环境中影响棉花生长的病虫害问题。为了有效检测这些问题，本文对 MobileNetV2 模型进行了一系列的改进，并基于此构建了一个专门用于棉花病虫害检测的模型。本文不仅对所做的每项改进进行了详尽的分析，还将其与其他现有的检测模型进行了性能上的对比研究。

实验结果证实，本研究中提出的改进措施有效地提升了模型的整体性能。改进后的 MobileNetV2 模型在准确率、LOSS 损失函数的优化以及参数量大小方面均展现出了优越性，超越了其他目标检测模型。

引入 EMA 注意力模块后的模型表现出了显著的性能提升。具体来说，可以观察到以下几个方面的改进：

(1) 损失值下降速度：在训练过程中，引入 EMA 模块的模型展现出更快的损失下降速度。这表明模型能够更有效地学习数据中的模式，更快地收敛到一个较优的解。

(2) 精确率提升：与基线模型相比，加入 EMA 模块的模型在验证集上的精确率提升速度更快。这表明模型的预测能力得到了增强，能够更准确地分类或预测目标变量。

(3) 参数量：尽管 EMA 模块增加了模型的复杂度，但可以发现其对参数数量的增加是有限的。实际上，与本文比较的其他五个算法相比，加入 EMA 模块后的模型参数量更小。这使得模型在保持性能的同时，也具有更好的泛化能力和计算效率。

因此，该改进模型不仅在理论上具有创新性，而且在实际应用中 also 具有很高的参考价值，可以为准确检测棉花病虫害提供有力的技术支持。

综上所述，本章不仅详细介绍了 MobileNetV2 模型的基本原理和结构，还深入探讨了如何通过改进这一模型来提高棉花病虫害检测的效果和实用性。通过实验对比分析和性能类比，本章为读者提供了一个清晰的视角，以理解和评估不同改进策略的效果，为未来的研究和应用提供了宝贵的经验和指导。

4 棉花病虫害识别系统的设计与实现

本章基于深度学习网络设计了棉花病虫害识别系统，通过该系统帮助农业从业人员识别棉花病虫害。深度学习模型研究最终要落入到实际项目中，通过第三章训练完毕的模型，本章考虑将之前完成的模型部署到服务器端，以方便用户实际操作为目的，从而满足实际应用的需求，通过使用 flask 部署 pytorch 模型进行实现。

4.1 系统需求分析

随着棉花病虫害的危害日益增长，农民对棉花病虫害识别的需求也日益增加。农民在识别棉花病虫害时，往往希望能通过自动化的方式对图像进行分析和识别，提高识别的准确性和效率。本章设计并实现的棉花病虫害识别系统能够实现上传图片后能够识别病虫害的功能，最后返回识别结果并且进行可视化展示。为了指导后续的设计系统和实现系统，本节将对系统进行需求分析，明确系统为用户提供的功能。

经过分析，本系统的具体功能包括：选择功能，识别功能以及可视化展示功能。选择功能需求分析：让用户可以从本地文件夹中的棉花病虫害图像中选择图像。识别功能需求分析：对用户所选的图像在后台进行相应识别。可视化展示需求分析：向用户展示可视化界面，包括系统主页面、选择图像页面、识别结果页面等。

4.2 系统的设计与功能

4.2.1 系统架构设计

本研究构建的系统架构被划分为三个主要层次：数据层、应用层和页面表示层。

在数据层，系统负责存储依据所提出的算法模型生成的识别结果。这些结果包含了一系列的文本信息，每个文本都对应一个预测类别，该类别是基于与真实标签的相似度进行匹配得出的最高相似度文本。

应用层的作用是响应用户的操作，当用户上传一张图像后，该层会在后台系统中检索该图像，并汇总所有算法处理后的文本结果。随后，这些经过整合的识别结果会被传递至用户界面展示层。

至于用页面表示层，其核心职责在于实现与用户的互动交流。具体来说，该层不仅提供图像选择功能，让用户可以从中选取感兴趣的图像进行查询，还负责将识别结果以直观的方式呈现给用户，以使用户能够轻松理解识别的最终成果。

本研究的系统架构图如图 4-1 所示。

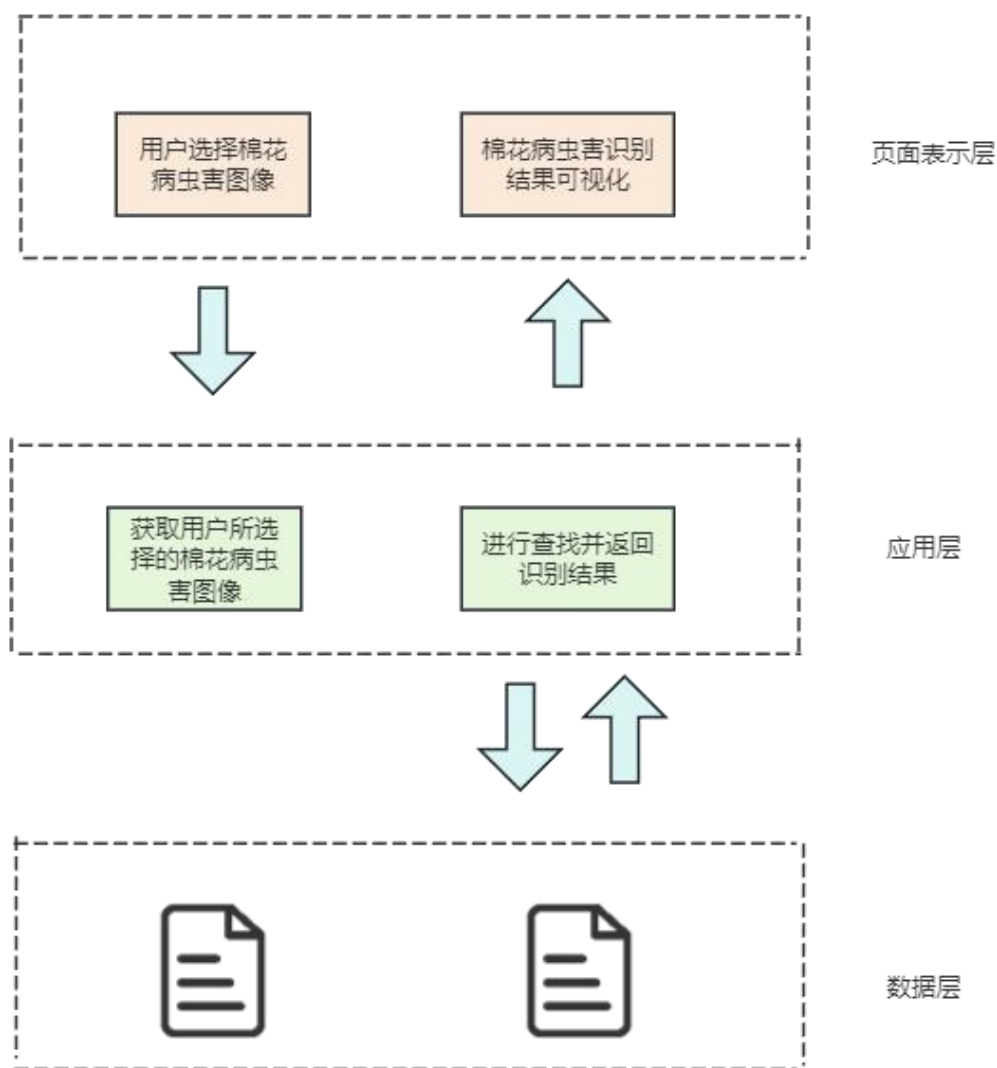


图 4-1 系统架构图

4.2.2 系统功能模块设计

本文系统的主要功能模块如图 4-2 所示，有选择功能模块，识别功能模块以及可视化展示模块。接下来对各模块展开详细说明。

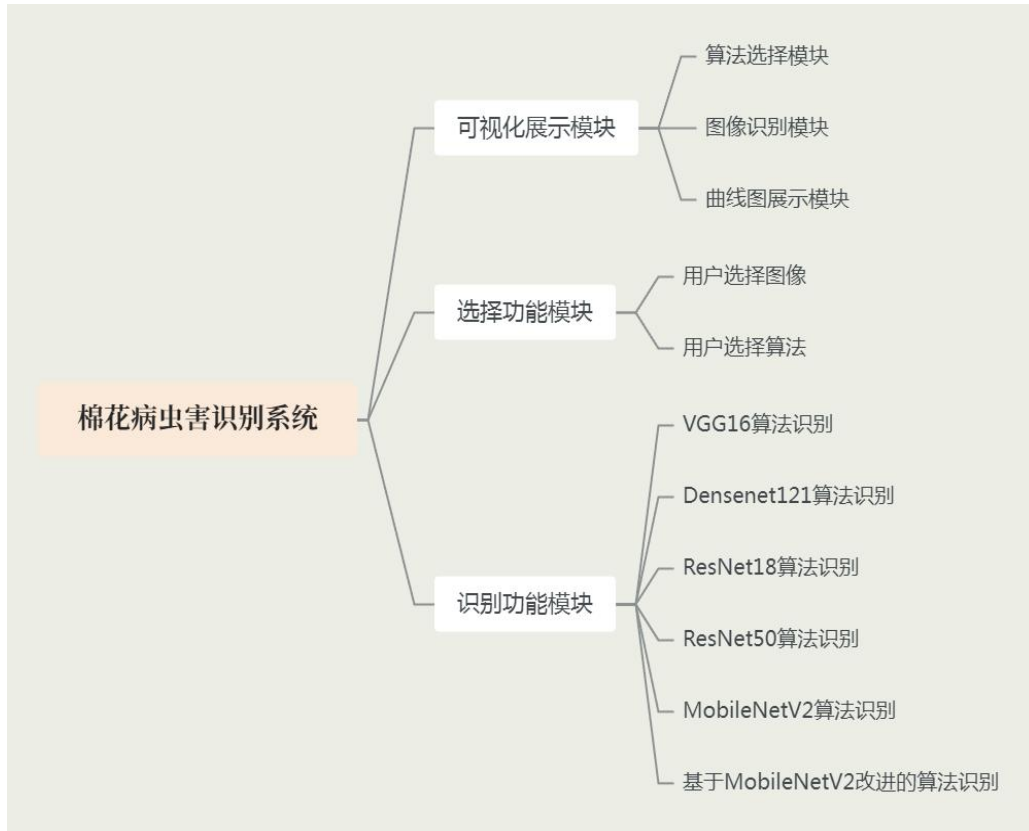


图 4-2 系统功能模块图

选择功能模块：用户从系统所显示的待查询棉花病虫害图像中搜索并选择图像信息进行搜索，以及从待查询算法中选择算法进行识别查询。

识别功能模块：系统在后台搜寻用户所选择的图像其对应的识别结果列表，然后将识别结果返回至页面。其中，识别结果列表储存在文本文件中，每个检索结果都对应一个预测类别，该类别是基于与真实标签的相似度进行匹配得出的最高相似度文本。

可视化展示模块：该部分主要是向用户展示可视化界面，具体包括：算法选择界面、图像识别界面、识别结果曲线图展示界面。

4.3 系统实现

在本项研究中，开发的棉花病虫害识别系统基于 Python 编程语言构建，利用其强大的数据处理能力和丰富的库支持，有效应对图像识别和机器学习等复杂任务。选择 Flask 框架作为后端开发基础来保持代码的简洁性和扩展性。

系统架构采用浏览器/服务器（B/S）模式，用户可以通过标准的 Web 浏览器访问系统，无需安装额外的客户端软件，从而提高系统的可访问性和便捷性。用

户界面通过 HTML 技术进行构建，组织和呈现网页内容。CSS 技术用于页面布局和元素样式的美化，以提供专业的界面效果和舒适的视觉体验。

为了增强系统的交互性和动态特性，前端集成了 JavaScript 技术，实现实时数据交互和动态内容更新，提升用户操作的流畅性和直观性。JavaScript 还支持实现高级前端功能，如表单验证、动态图表展示和用户行为跟踪等，增强系统的功能性和操作便利性。

综上所述，该棉花病虫害识别系统在技术选型、架构设计和用户体验等方面进行了全面的规划和精细的实现，旨在提供一个高效、准确、易用的病虫害识别工具，以期在实际应用中取得显著效果。

本文系统主要由“上传图片”、“选择算法进行识别”、“可视化展示”部分组成。用户可以通过在“上传图片”选择“加号”模块来进行棉花病虫害图像上传功能，用户可以通过在侧栏选择“待查询算法”模块来使用算法进行识别功能，本节将对系统功能展开介绍。

系统登录页面如图 4-3 所示。用户通过输入用户名和密码点击登录，验证通过后可以进入棉花病虫害识别系统主界面。

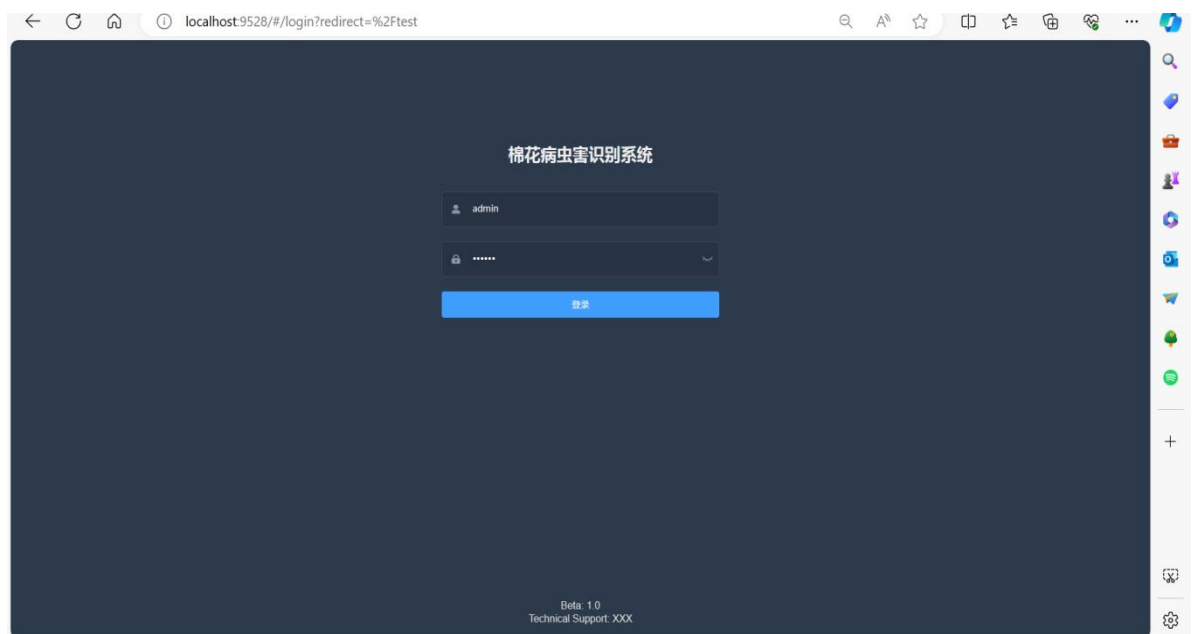


图 4-3 系统登陆界面

系统的主界面如图 4-4 所示，用户可以在系统主界面中选择待查询的图像和文字，并将页面跳转到对应的检索结果界面。

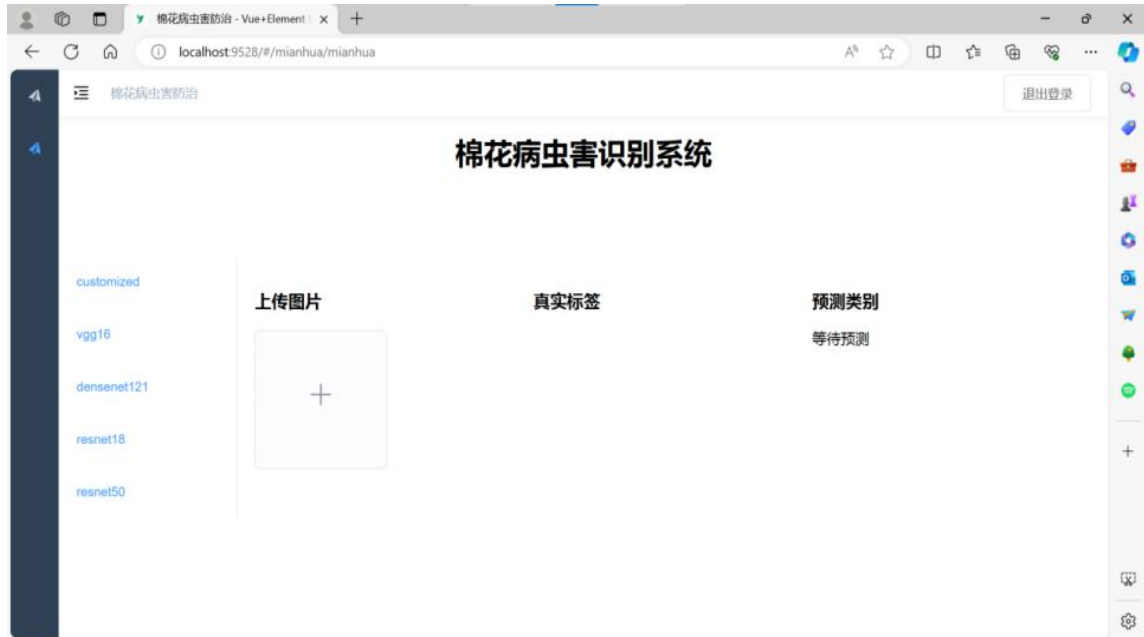


图 4-4 系统主界面

如图 4-5 所示，用户可以通过点击上传按钮进行上传棉花病虫害图片。



图 4-5 上传图片

在本章节中，采用了一种简化的 PC 端系统架构，因此并未为其创建一个独立的数据库。相反，本文选择了一种替代方案，即将标签数据以列表的形式直接嵌入到 Java 类文件中。这些标签文件构成了识别系统的信息库，它们负责存储棉花病害的各类名称。每个标签索引都与特定的病害种类名称精确匹配，确保了信息的准确性和检索的便捷性。

在系统中点击上传棉花叶片病虫害图像并点击侧边栏的算法开始识别，将检测结果展示在页面回馈给用户。识别模块允许用户上传本地图像文件，并将其发

送到后端进行处理。主要通过调用实验中改进的 MobileNetV2 检测模型来识别棉花病虫害图像，然后会在页面显示识别结果和相应的 ACC 曲线图和 LOSS 损失函数曲线，算法识别结果如图 4-6 所示。

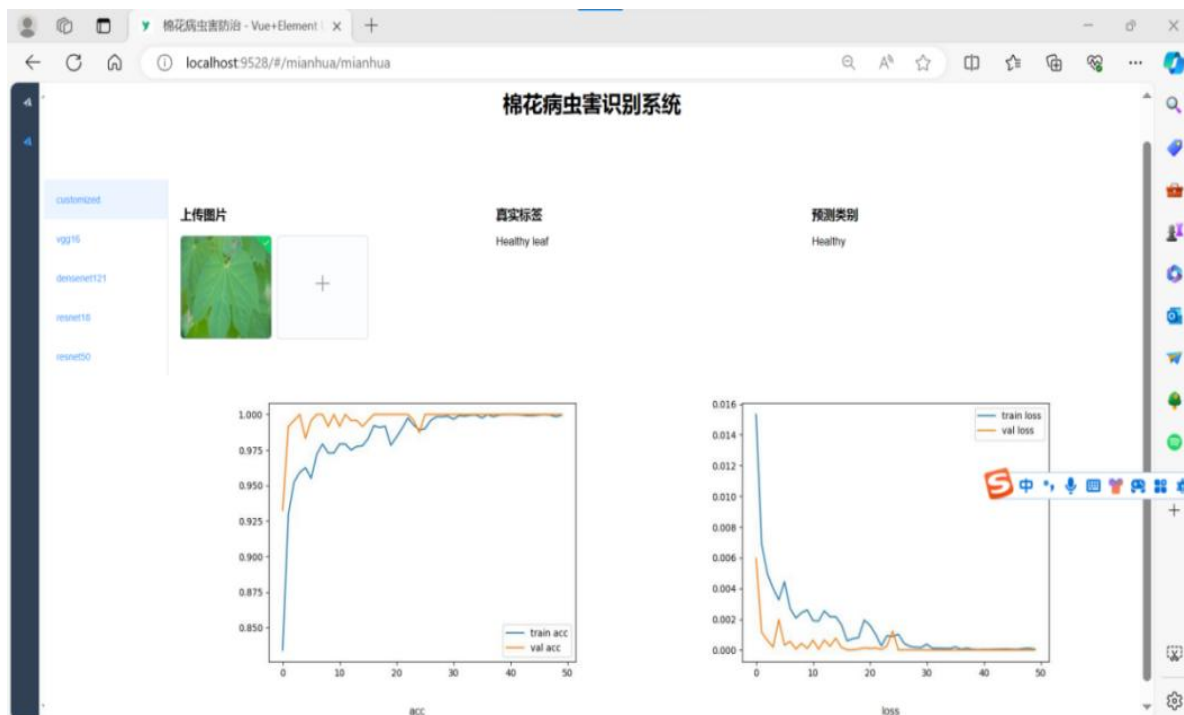


图 4-6 选择算法

4.4 系统测试

系统测试是系统开发完成之后在线投入使用前不可缺少的一环，通过系统测试不仅可以验证前面分析部分提出的各功能模块是否正常实现，还要测试系统能否在操作系统上安全运行、是否与硬件设施以及其他安装的软件兼容等。同时用户体验对于识别系统来说也至关重要，如果识别结果准确度高、识别速度快，那么才能帮助农户解决病虫害问题。本小节将对棉花病虫害识别系统各功能模块进行测试，检验其是否能正常运行使用。

4.4.1 软硬件环境

软件开发与配置环境如下：

- (1) 开发工具：Visual Studio Code
- (2) 编程语言：python 语言
- (3) 开发框架：Flask 框架

操作系统：Windows10

4.4.2 测试内容

（1）系统非功能性需求测试

首先对病虫害识别系统的非功能需求进行测试，本系统通过用户上传照片来检测棉花病虫害，经过一系列的测试，系统的识别准确率较高。其次，在第三章模型分析部分可以看到模型识别的速度很快，所以系统具有很好的实时性。用户上传图片过后，很快就返回检测结果。接下来是系统的易用性，系统界面简洁明了，操作简便，具有很强的易用性。最后棉花病虫害系统使用的改进的 MobileNetV2 模型可以换成其他卷积神经网络识别模型，所以本系统扩展性较好。

（2）系统功能测试

表 4-1 系统功能测试

编号	测试内容	期望测试	测试结果	成功/失败
1	测试用户能否选择棉花病虫害图像进行上传	进入图像上传模块，点击文件上传，选择图像上传，提示上传成功	成功上传图像	成功
2	测试图像上传模块上传其余文件	点击文件上传，选择其他类型文件进行上传，上传失败	上传失败	成功
3	测试用户能否进行图像识别	上传需要识别的棉花病虫害图像，显示出图像的预测类别结果	显示出预测类别	成功
4	测试用户能否选择不同的算法	点击算法模块，选择其中一种算法，显示出算法的识别结果	显示出识别结果	成功

功能测试的测试对象为系统的各个功能模块，其目的是测试本系统的各个功能是否能正常使用并且符合预期操作结果。本文主要对算法选择、图像选择、图像识别以及系统的完整性进行测试，测试结果如表 4-1 所示。

4.5 本章小结

本章节详细阐述了系统设计与实现的全过程。首先对系统需求进行了深入分析；其次，详细说明了设计阶段，包括系统的架构规划和各功能模块的设计思路；进一步，描述了系统实现的具体步骤，并附上了界面设计图的展示；最终，对系统进行了全面的测试，包括界面和功能模块的检测，并呈现了相应的测试结果。

本章节是关于系统设计与实现过程的详尽描述。它从系统需求分析开始，深入探讨了系统设计和实现的每个关键步骤。

系统设计与实现的全过程首先以系统需求分析为起点。在这一阶段，通过目标用户群体的调研、市场趋势的分析以及技术可行性的评估，收集了必要的信息，确保系统设计能够满足用户的实际需求，并具备市场竞争力。

随后，进入设计阶段，系统架构的规划成为首要任务。模块化设计方法被采用，以便于未来的扩展和维护。紧接着，对每个功能模块进行了详细的设计，这涉及用户界面的布局、业务逻辑的处理以及数据存储的结构。在设计过程中，用户体验被特别重视，以确保系统既直观又易于使用。

进一步地，描述了系统实现的具体步骤。这包括从编码到部署的每一个环节。迭代的开发方法被采用，以确保在开发过程中能够及时收集反馈并进行调整。在实现过程中，不仅关注功能的实现，还注重代码的质量和系统的稳定性。为了更好地展示工作成果，附上界面设计图，这些设计图不仅展示了系统的外观，还体现了对用户交互的深入思考。

最终，系统经过了全面的测试。测试工作涵盖了界面的美观性、易用性以及功能模块的完整性和稳定性。自动化测试和手动测试相结合的方法被采用，以确保测试的全面性和准确性。测试结果显示系统在大多数情况下能够正常运行，且用户反馈良好。发现的问题得到了及时修复，并在测试报告中详细记录了测试过程和结果，为系统的后续改进提供了宝贵的参考。

通过本章节的详细阐述，得知从需求分析到设计规划，再到实现步骤和最终的测试，每一个环节都是构建一个成功系统不可或缺的部分。这种系统化的方法可以大大提高系统开发的成功率，并最终交付一个高质量、用户友好的系统。

5 总结与展望

5.1 总结

在过去的几年中，深度学习技术已经在计算机视觉领域取得了显著的进展，尤其是在图像识别任务中。棉花作为全球重要的农作物之一，其生长过程中易受到多种病虫害的影响，这不仅影响棉花的产量和质量，还可能导致严重的经济损失。因此，及时准确地识别棉花病虫害对于农业生产具有重要意义。本文旨在研究深度学习在棉花病虫害图像识别领域的应用，并通过引入注意力机制来提高卷积神经网络（CNN）的识别性能。

为了实现这一目标，本文首先对现有的 CNN 模型进行了深入分析，选择了经典的 MobileNetV2 模型作为基础架构。MobileNetV2 是一种高效的深度学习模型，它通过使用深度可分离卷积来减少计算量和模型参数，从而在保持较高识别精度的同时，实现了较快的处理速度和较低的资源消耗。然而，尽管 MobileNetV2 在多个图像识别任务中表现出色，但其对图像中关键区域的关注程度仍有待提高。

为了解决这一问题，本文提出了一种基于注意力机制的 MobileNetV2 算法。注意力机制能够使模型更加关注图像中的重要特征，从而提高模型对棉花病虫害的识别能力。通过在 MobileNetV2 模型中引入自注意力模块，本研究的设计能够自动学习到图像中与病虫害相关的显著特征，并将这些特征作为识别的关键信息。此外，本文还对注意力模块的结构和参数进行了优化，以确保模型的效率和准确性。

为了验证所提出算法的有效性，本文在棉花病虫害数据集上进行了实验，并与其他五种主流的图像识别算法进行了对比。实验结果表明，本文提出的基于注意力机制的 MobileNetV2 算法在 ACC 准确率、LOSS 损失函数和参数量等评价指标上均优于其他算法。这一结果证明了注意力机制在提高棉花病虫害图像识别任务中的有效性。

基于上述研究成果，本文进一步设计并实现了一套基于改进的 MobileNetV2 模型的棉花病虫害识别系统。该系统具有用户友好的界面和简洁的操作流程，使得普通用户也能够轻松地使用该系统进行棉花病虫害的识别和分类。

综上所述，本文通过引入注意力机制对 MobileNetV2 模型进行了改进，并在棉花病虫害图像识别任务中取得了优异的实验结果。此外，本文还开发了一套基于改进模型的识别系统，为棉花病虫害的防治提供了有力的技术支持。未来的研究可以进一步探索注意力机制在其他类型的图像识别任务中的应用，以及如何结合其他先进的深度学习技术来提高模型的性能。

5.2 展望

在本研究中，将 MobileNetV2 模型和注意力机制成功地结合，应用于棉花病虫害图像识别任务，并取得了显著的成效。通过这种结合，模型能够更加准确地识别和分类棉花病虫害图像，从而为农业病虫害管理提供了有效的技术支持。然而，尽管取得了一定的成果，但同时也意识到现有研究仍存在一些局限性，需要在未来的工作中加以改进和完善。

首先，目前使用的棉花病虫害数据集图片数量有限，这可能限制了模型的泛化能力和识别精度。为了解决这一问题，未来的工作将着重于与农民和农业专家建立紧密的联系，搜集更多样化和数量充足的棉花病虫害图片。这不仅包括常见的病虫害类型，还应涵盖罕见和新出现的病虫害情况。此外，对收集到的图片进行准确的标注和整理也是至关重要的，这将为构建高质量、具有良好代表性的棉花病虫害数据集奠定基础。

其次，目标检测技术在近年来得到了广泛的关注和快速的发展，已被证明在多个领域中具有高效的应用潜力。考虑到目标检测技术能够识别图像中的多个对象及其位置，本文提议将其与现有的棉花病虫害识别系统相结合。通过集成目标检测技术，系统不仅能够识别病虫害的类型，还能够精确地定位棉花病虫害的位置，从而提高整个系统的使用效率和实用性。

最后，为了进一步提升系统的普及率和便捷性，未来的工作计划将开发适用于 iOS 和 Android 平台的手机客户端。通过手机客户端，用户可以随时随地使用该系统进行棉花病虫害的识别，无需依赖于专业的设备或复杂的操作流程。这将极大地方便农民和农业工作者在田间地头进行实时的病虫害监测和管理，提高农业生产的智能化水平。

综上所述，本文期望能够进一步提升棉花病虫害图像识别技术的性能和应用范围，为农业病虫害管理提供更加全面和有效的解决方案。

参考文献

- [1] 侯发东. 基于卷积神经网络的棉花叶部病虫害自动识别研究[D]. 山东农业大学, 2020.
- [2] 张建华, 孔繁涛, 吴建寨, 等. 基于改进 VGG 卷积神经网络的棉花病害识别模型[J]. 中国农业大学学报, 2018,23(11):161-171.
- [3] 赵立新, 侯发东, 吕正超, 等. 基于迁移学习的棉花叶部病虫害图像识别[J]. 农业工程学报, 2020,36(07):184-191.
- [4] 史冰莹, 李佳琦, 张磊, 等. 基于 CNN 的农作物病虫害图像识别模型[J]. 计算机系统应用, 2020,29(06):89-96.
- [5] 地力夏提·依马木, 周建平, 许燕, 等. 基于 Logistic 算法与遥感影像的棉花虫害监测研究[J]. 华南农业大学学报, 2022,43(02):87-95.
- [6] K. Dong, C. Zhou, Y. Ruan and Y. Li. MobileNetV2 Model for Image Classification[C]. 2020 2nd International Conference on Information Technology and Computer Application (ITCA), Guangzhou, China, 2020: 476-480.
- [7] Yuntao H ,Zequan W ,Xiaohua C , et al. The application of improved densenet algorithm in accurate image recognition[J]. Scientific Reports, 2024,14(1).
- [8] D. Radha and S. Prasanna, "A unique ADAGRAD optimized DCNN with RESNET-18 Architecture for Indoor Agriculture-Based Crop Yield[C], 2024 IEEE International Conference on Computing, Power and Communication Technologies (IC2PCT), Greater Noida, India, 2024:767-771.
- [9] Li X ,Fang J ,Zhao Y .A Multi-Target Identification and Positioning System Method for Tomato Plants Based on VGG16-UNet Model[J]. Applied Sciences, 2024,14(7).
- [10] Qiming Z ,Hongwei Z ,Mi Z , et al. A study on expression recognition based on improved mobilenetV2 network[J]. Scientific Reports, 2024,14(1):8121-8121.
- [11] Y. Li, J. Zeng, S. Shan and X. Chen, Occlusion Aware Facial Expression Recognition Using CNN With Attention Mechanism[C]. IEEE Transactions on Image Processing, vol. 28, no. 5, 2019: 2439-2450.
- [12] D. Ouyang et al., Efficient Multi-Scale Attention Module with Cross-Spatial Learning[C]. ICASSP 2023 - 2023 IEEE International Conference 60090. 2024.10486749.
- [13] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition[C]. In Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR) (pp. 770-778). on Acoustics, Speech and Signal Processing (ICASSP), Rhodes Island, Greece, 2023:1-5.
- [14] Chen H ,Zhou G ,He W , et al. Classification and identification of agricultural products based on improved MobileNetV2.[J]. Scientific reports, 2024,14(1):3454-3454.

- [15] Aydin C .Enhanced Material Classification via MobileSEMNet: Leveraging MobileNetV2 for SEM Image Analysis[J].Traitement du Signal,2023,40(6).
- [16] E. R. and T. Manoranjitham, Classification of diseases in Paddy by using Deep transfer learning MobileNetV2 model[C].2022 1st International Conference on Computational Science and Technology (ICCST), CHENNAI, India, 2022:936-940.
- [17] L. Ou and K. Zhu, Identification Algorithm of Diseased Leaves based on MobileNet Model[C].2022 4th International Conference on Communications, Information System and Computer Engineering (CISCE), Shenzhen, China, 2022:318-321.
- [18] K. Ajay, R. V. C. Sathvik, B. Naseeba and N. P. Challa, Paddy Crop Disease Detection using LeNet and MobileNet Models[C].2024 11th International Conference on Computing for Sustainable Global Development (INDIACom), New Delhi, India, 2024: 597-602.

致 谢

四年时光转瞬即逝，不知不觉间已经到了毕业季，随着这篇论文的最后一个个句号的落定，我满怀感慨地回望了大学四年的求学之路。这一段旅程，充满了挑战与成长，喜悦与茫然，如今到了告别的时刻，心中充满了不舍与感激。

首先，我要向我的指导老师程述立教授表达我最深切的敬意和感谢。在本科论文的撰写过程中，程教授不仅以他深厚的学识和严谨的学术态度给予我无私的指导，更在精神上给予我巨大的支持。每当我在学术探索的旅途中遇到难题，程教授总能以其丰富的经验和独到的见解为我指明方向。他的耐心指导和专业建议，对论文的完善起到了决定性的作用。在此，我也要感谢刘江学长，他的无私帮助和宝贵建议对我也有很大的帮助。

同时，我也要向王克丰老师表达我的感激之情。作为我的班主任，王老师不仅在学业上给予我悉心的指导，更在生活上给予我无微不至的关怀。

此外，我还要感谢所有教授过我的老师们。是您们的专业教导和无私奉献，为我打下了坚实的专业基础，让我在学术的道路上不断前行。

感谢我的同学们，与你们一起度过的四年，是我一生中最宝贵的记忆。我们共同学习，共同进步，感谢你们给予我的帮助和陪伴。

最后，我要感谢我的家人。是你们在我学习和生活中始终如一的支持和鼓励，给了我勇往直前的力量。没有你们，就没有我今天的成就。

感谢所有在这四年中给予我帮助和支持的人，是你们让这段旅程充满了意义和价值。未来的道路还很漫长，我将带着这份感激和收获，继续前行。